

사용 기술 및 전략 설명서

팀 쉬엠팀 · 제출 모델 EXT-FULL-v7 · 리더보드 L2_avg 0.117067

개요

이 모델은 6개 카메라 영상과 과거 전방 영상에서 미래 3초 궤적(0.5 s 간격 6점)을 예측하는 end-to-end 네트워크입니다. 핵심 전략은 세 가지입니다.

- 영상 중심의 공통 장면 표현:** 모든 카메라 영상을 BEV 격자(차량 기준 위에서 본 평면)로 모읍니다. ego 상태와 목표점은 "어떤 영상 정보를 읽을지"를 정하는 조건으로만 쓰고, 좌표 계산에는 넣지 않습니다.
- 영상 기반 움직임 인식:** 현재와 과거 전방 영상의 대응 관계에서 자차 움직임을 인식하고, 이를 planner의 입력으로 씁니다. 이 경로는 pose나 속도 값을 받지 않습니다.
- 후보 생성 + 목표점 선택:** planner가 서로 다른 궤적 후보 15개를 5초까지 생성합니다. 5초 끝점이 목표점에 가장 가까운 후보를 좌표 변경 없이 출력합니다.

학습은 3단계입니다. 1단계는 공개 백본에서 전체 모델을 학습합니다. 2단계는 낮은 학습률로 추가 학습합니다. 3단계는 몸통을 동결하고 후보 생성 planner를 학습합니다.

용어

용어	뜻
BEV	Bird's-Eye View. 차량 주변을 위에서 내려다본 평면 격자입니다(차량 기준 앞 -10~70 m, 좌우 ±32 m, 64×48 칸)
목표점	대회가 제공하는 +50 frame(5초 뒤) 위치입니다
ego 상태 5값	현재 속도 vx·vy, 가속도 ax·ay, yaw rate입니다. 과거 pose에서 계산합니다
held-out 모델	설정을 고르려고 학습 데이터 일부(tune 37 scenario)를 빼고 학습한 모델입니다
tune 평가	tune 37 scenario(1,998 샘플)에서 계산한 평가식 L2입니다
평가식 가중 L2 (d3)	6개 waypoint의 L2 오차에 평가식과 같은 가중치 [11, 11, 5, 5, 2, 2] / 36을 곱한 값입니다
update	optimizer step 1회입니다(batch 16)

1. 결과 요약

- 리더보드 L2_avg **0.117067** (L2_1s 0.0654, L2_2s 0.1153, L2_3s 0.1705)입니다.
- clip당 forward 1회이고, __flops__ 는 743.8 G(cutoff 7,053 G)입니다. RTX 4090 추론 시간은 약 31 ms입니다.

2. 입력과 사용 경로

입력	사용 경로
6개 카메라 현재 영상	백본 → 공통 BEV(scene) 특징, 전역 영상 문맥
전방 카메라 과거 영상 (-0.1 / -0.2 / -0.5 / -1.0 s)	768×432는 motion encoder, 384×216은 scene의 과거 시점 샘플링에 사용합니다
과거 ego pose	(a) 위 과거 4 프레임의 기하 정렬, (b) 현재 ego 상태 5값(vx, vy, ax, ay, yaw rate) 계산

입력	사용 경로
현재 ego 상태 5값	공통 scene attention의 query 조건으로만 사용합니다. planner와 motion encoder에는 입력하지 않습니다
5초 목표점 (+50 frame)	(a) 공통 scene attention의 query 조건, (b) 후보 궤적 선택 (5초 끝점과의 거리가 가장 작은 후보)
command, vad_cmd	사용하지 않습니다

과거 궤적과 ego 상태는 planner에 직접 입력하지 않고, 단순 임베딩으로도 입력하지 않습니다. 최종 궤적 좌표는 모두 영상 특징을 읽는 planner가 생성합니다. 영상을 단색으로 바꾸면 held-out L2가 0.129에서 3.877로 크게 나빠집니다.

2.1 전처리 (추론 코드에 포함)

- **영상:** 카메라별 왜곡을 보정합니다(일반 렌즈와 어안 렌즈 모두). 이어서 1920×1080 영역을 잘라내고 0.4배로 줄여 768×432 로 만듭니다.
 - 전방과 후방 광각 카메라는 하단을, 측방 4개 카메라는 상단을 기준으로 자르고, 가로는 중앙을 기준으로 자릅니다.
 - 학습 캐시와 같은 입력이 되도록 JPEG(품질 95)로 한 번 다시 인코딩합니다.
 - scene용 과거 영상은 같은 시야를 384×216 으로 줄입니다.
 - 정규화는 공개 ResNet 가중치와 같은 ImageNet 평균·표준편차를 사용합니다.
- **카메라 행렬:** 보정된 intrinsic에 crop-resize를 반영한 lidar2img를 사용합니다.
- **목표점:** ego_pose.parquet 의 +50 frame 위치를 현재 ego 좌표계로 변환한 XY입니다. 미래 방향(자세)은 읽지 않습니다.
- **현재 ego 상태 5값:** 영상을 입력하는 5개 시점(0, -0.1, -0.2, -0.5, -1.0 s)의 pose에 2차 다항식을 최소제곱으로 적합합니다. vx·vy·ax·ay는 위치 적합의 1·2차 계수이고, yaw rate는 yaw 적합의 1차 계수입니다. 적합 잔차(RMS)가 0.25 m를 넘으면 오류로 처리합니다.

3. 모델 구조




그림 원본은 docs/architecture.dot 입니다. 점선은 조건·기하 정보가 들어가는 경로이고, 실선은 영상 특징이 흐르는 경로입니다.

모듈	파라미터	주요 크기
백본 (ResNet-50 + FPN)	24.26 M	현재 6장 768×432, scene용 5장 384×216, motion용 5장 768×432. 패스는 3회입니다
Scene encoder	0.39 M	BEV 64×48 = 3,072셀, 셀당 영상 샘플 60개
Motion encoder	1.36 M	motion token 192개 (12×16)
Planner	0.64 M	후보 15개 × 10점
ego 상태 query 조건	0.001 M	MLP 5→32→32

모듈	파라미터	주요 크기
합계	26.66 M	1회 forward 743.8 GFLOPs

- 백본:** ResNet-50과 경량 FPN(128채널)이고, 모든 영상이 하나의 백본을 공유합니다.
 - 현재 6개 카메라 영상은 768×432 로 읽습니다.
 - scene용 전방 영상 5장(현재 축소본 1장과 과거 4장)은 384×216 으로 읽습니다.
 - motion용 전방 영상 5장(현재 1장과 과거 4장)은 768×432 로 읽습니다.
- 공통 scene encoder:**
 - BEV 격자 셀마다 query를 둡니다. query는 셀 위치, 목표점 상대 위치, ego 상태 조건으로 구성됩니다.
 - 각 셀의 3D 샘플 점을 카메라에 투영해 현재·과거 영상 특징을 샘플링하고, attention으로 읽습니다(2회 refinement). query는 어떤 영상 증거를 읽을지만 결정하고, 읽히는 값은 영상 특징입니다.
 - 셀마다 3개 높이($0.1 \sim 2$ m)와 10개 시점(현재 6개 카메라, 과거 전방 4장), 2개 FPN 레벨에서 영상 샘플 60개를 읽습니다. 과거 시점은 과거 ego pose로 투영 위치만 맞춥니다.
 - 전역 영상 문맥과 셀 간 residual attention을 더합니다. residual attention은 4×4 로 묶은 192개 영역에서 영상 특징을 모읍니다. 이 경로에는 목표점 대신 0을 입력하므로, 목표점을 사용하지 않는 구조입니다.
 - 이어서 SpatialMix(depthwise 3×3 합성곱과 1×1 MLP로 구성된 residual 블록) 2개로 정제합니다. 결과 특징은 occupancy head, lane head, planner가 공유합니다.
- Motion encoder:** 768×432 현재·과거 전방 특징 쌍의 correlation(반경 4, 81 bin, FPN 2레벨)으로 시점별 pair 특징(4×192)을 만들고, 시점 attention으로 합쳐 motion token 192개를 만듭니다. 영상만으로 ego 상태와 과거 궤적을 예측하는 보조 head를 가지며, pose·목표점·ego 상태 입력은 없습니다.
- Planner:**
 - transformer decoder(2층, 4 head)가 waypoint query 6개로 memory를 읽습니다. memory는 scene token 3,072개, motion token 192개, 영상 예측 상태 token 1개입니다.
 - waypoint마다 시간별 motion 특징을 다시 읽습니다(temporal read).
 - 출력은 구간마다 이동 길이(softplus)와 진행 방향을 예측하고 누적해 위치를 만드는 구조입니다.
- 후보 확장 and 선택 (3단계):**
 - planner가 후보 궤적 **15개**(종방향 5 $\times$ 횡방향 3)를 생성합니다. 후보마다 mode 임베딩과 길이·방향 bias를 학습합니다.
 - bias 초기값은 5.0 s에서 종방향 ± 0.06 (길이 단위), 횡방향 ± 0.04 rad로 균등하게 벌린 값입니다. 설정값은 Dockerfile의 EXT_* 환경변수입니다.
 - 각 후보는 **5초까지 10점**입니다. 3.5~5.0 s 구간은 6번째 구간에 학습된 잔차를 더해 만듭니다.
 - 추론 시에는 $\text{argmin}_k \|\text{후보}_k(5.0 \text{ s}) - \text{목표점}\|$ 으로 후보 하나를 고르고, 앞 6점(0.5~3.0 s)을 좌표 변경 없이 출력합니다.
 - 선택에는 학습 모듈을 사용하지 않고, ego 상태와 과거 정보도 사용하지 않습니다. 영상 입력부터 출력까지 하나의 네트워크입니다.

4. 학습

4.1 공통 설정

대회 제공 train 376 scenario에서 frame 30 이상 전체(101,520행)를 사용합니다. 최적화는 AdamW(weight decay 0.01), BF16, BN 통계 고정, gradient clip 5이고, seed는 1입니다. 모든 단계는 NVIDIA B200 GPU 1장으로 학습합니다.

4.2 단계별 설정

	1단계	2단계	3단계
시작점	공개 초기값	1단계 산출	2단계 산출
학습 대상	전체	전체	planner와 후보 확장 파라미터 (몸통 동결)
update / batch	24,931 / 16	38,070 / 16	6,344 / 16 (학습 행을 2 프레임 간격으로 추린 50,760행, 2 epoch)
학습률	backbone 5e-6, head 5e-5, warmup 200, cosine	backbone 1e-6, head 1e-5, warmup 100, cosine	planner 2e-5, 신규 1e-3, warmup 100, cosine
손실	평가식 가중 L2 + 구간 길이 보조(λ 0.25) + occupancy·lane BCE(각 0.2) + motion 보조(0.2, ego 상태·과거 궤적 회귀는 불확실성 가중)	1단계와 동일	배정된 후보의 평가식 가중 L2 + $0.3 \times$ 5초 연장 구간 L2
증강	좌우 반전 ($p=0.5$)	1단계와 동일	없음
학습 시간 (B200 1장)	약 3.6시간	약 5.6시간	약 0.7시간

4.3 손실 구성

occupancy·lane 손실은 scene encoder에 붙은 보조 head에 걸립니다. planner는 occupancy·lane 예측값을 입력으로 받지 않습니다. 대신 이 손실의 gradient가 공통 scene 특징과 백본을 학습시키고, planner는 그 scene 특징을 읽는 구조입니다. 3단계에서는 몸통과 보조 head를 동결하므로 이 손실을 쓰지 않습니다.

보조 감독 정답 (모두 train 주석에서 생성합니다. `src/data_prep/build_scene_supervision_v2.py`)

- **occupancy:** 현재 프레임에 주석된 주변 객체(점 1개 이상)의 BEV footprint입니다. 카메라에 보이지 않는 셀과 주석 완전성을 보장할 수 없는 셀은 손실에서 제외합니다.
- **lane:** `map.parquet`의 차선 polyline을 BEV에 그린 raster입니다. 알려진 차선에서 약 8 m 이내이고 카메라에 보이는 셀만 손실에 사용합니다.
- **motion:** train ego pose에서 계산한 현재 ego 상태, 과거 궤적 4점, 정지 여부입니다. motion encoder는 이 값을 영상만으로 예측하도록 학습합니다. 상태와 궤적은 회귀로, 정지 여부는 BCE로 학습합니다. 이 예측값이 planner의 상태 token이 됩니다.
- **구간 길이 보조:** 인접 waypoint 사이 이동 길이의 오차입니다. 누적 출력 구조에서는 앞 구간의 오차가 뒤의 모든 위치로 전파됩니다. 그래서 각 구간에 평가 가중치의 곱리 합($1.00 \cdot 0.69 \cdot 0.39 \cdot 0.25 \cdot 0.11 \cdot 0.06$)을 평균 1로 정규화해 공급합니다.

4.4 증강과 연산 정밀도

좌우 반전 증강: 카메라 쌍(전방좌↔전방우, 후방좌↔후방우)을 서로 바꾸고 영상을 반전합니다. 카메라 행렬, 과거 pose 변환, 목표점, 정답 궤적도 함께 $y \rightarrow -y$ 로 반전합니다. 추론에는 사용하지 않습니다.

연산 정밀도: 백본과 encoder는 BF16 autocast로 계산합니다. planner, 좌표 head, 후보 선택은 FP32로 계산합니다.

4.5 3단계 후보 배정

학습 샘플마다 5.0 s 끝점이 정답 5.0 s 위치에 가장 가까운 후보를 골라 그 후보를 학습합니다. 학습 데이터에서 정답 5.0 s 위치는 목표점(+50 frame)과 같으므로, 학습과 추론이 같은 선택 규칙을 사용하는 구조입니다. 학습이 끝난 뒤 tune 1,998 샘플에서 15개 후보가 모두 선택되며, 후보당 23~236회입니다.

5. 검증 전략

- **held-out 모델:**
 - 376개 scenario를 시간 연속 session 단위로 train 310 / tune 37 / val 29로 나눕니다(data/split.json).
 - 설정 결정은 train 310개로 학습한 held-out 모델을 tune 37개 scenario(11 session, 1,998 샘플)로 평가해 했습니다.
 - 제출 모델은 같은 설정을 376개 scenario 전체에 적용했습니다.
 - 판정에는 session 단위 bootstrap(2만 회)과 개선 session 수를 사용했습니다.
- **후보 수 결정:**
 - held-out에서 후보 수 6·9·15·27·35·63·77개를 비교했습니다.
 - 후보 수가 늘면 주행 구간 오차는 줄지만 정지 근처 구간 오차는 늘었습니다.
 - 두 구간 모두에서 안정적인 15개를 채택했습니다.

6. 실험 요약

효과가 있었던 기법	held-out 효과
학습 데이터 확대 (203 → 310 → 339 → 376 scenario)	가장 일관된 개선
공통 scene query의 ego 상태 조건	큰 개선
구간 길이·방향 출력, waypoint별 temporal read, 낮은 학습률 추가 학습	각각 개선
영상 후보 생성 + 목표점 기반 선택	-7.7% (서버 -10.5%)

효과가 없었던 기법	비고
과거 프레임 추가(6시점), 측방 과거 영상, 주변 차량 미래 궤적 보조 감독, optical flow 증류	가감속·회전 구간에서도 $\pm 2\%$ 이내
입력 해상도 1152, ResNet-101	—
checkpoint 평균, 가중치 soup, 학습 연장, 몸통 포함 재학습	—
command 필터, 목표점 방향 가중 선택	목표점 끝점 선택과 정보가 겹칩니다

7. 재현성

- **학습:** 같은 코드와 seed로 다시 학습하면 종료 값이 원래 값 근처로 재현됩니다. BF16과 비결정적 CUDA 누적 연산 때 문에 비트 단위로는 같지 않고, 중간 곡선은 벌어졌다가 끝에서 수렴합니다.

단계	원래 tune 평가	재현
1단계 전체	0.106606	0.106857
2단계 + 3단계 연쇄	0.091885 / 0.087320	0.091843 / 0.087321
3단계 전체	0.087320	0.087342, 0.087666

- **추론:** 이 제출물의 Docker 이미지로 RTX 4090에서 테스트 1,125 clip을 추론하면 1,118 clip이 제출본과 같은 후보를 고르고, 가중 좌표 차이 평균은 0.9 mm입니다. 학습 서버(B200)에서는 1,125 clip 모두 제출본과 완전히 같습니다.
- 자세한 수치와 방법은 `VALIDATION.md`에 있습니다.