

# 검증 결과

이 문서는 제출물이 리더보드 제출 결과를 재현하는지 확인한 기록입니다. 1절은 제출 Docker 이미지로 RTX 4090에서 실행한 기본 검증(`scripts/validate.sh`)입니다. 2절은 학습 서버에서 수행한 학습 재현입니다. 3절은 제출물 폴더 구조 그대로 데이터 준비, 학습, 추론 전 과정을 실행한 결과입니다.

## 1. 이 제출물의 Docker 이미지로 RTX 4090에서 실행 (`scripts/validate.sh`)

- 환경: NVIDIA GeForce RTX 4090, 컨테이너 torch 2.7.1+cu128
- 결과 원문: `validation/result/validation.json`
- 테스트 clip 20개는 대회 테스트 폴더에서 읽습니다(`bash scripts/validate.sh /path/to/test`). 제출물에는 이 clip들의 참조 예측만 들어 있습니다.

| 항목                                              | 결과                                                   |
|-------------------------------------------------|------------------------------------------------------|
| FLOPs (FlopCounterMode, 1회 forward 전체)          | 743,777,233,600 (제출 <code>__flops__</code> 와 같습니다)   |
| 1회 forward 시간 (BF16, 전처리 제외, warmup 20회 후 100회) | 중앙값 <b>30.8 ms</b> , p95 31.3 ms (시간 가중치 ×1.0)       |
| 학습 clip 8개, 학습 서버(B200) 예측과 비교                  | 좌표 최대 차이 중앙값 2.2 mm, 최대 4.2 mm, 선택 후보 8/8 일치         |
| 테스트 clip 20개, 실제 제출 파일과 비교                      | 좌표 최대 차이 중앙값 1.5 mm, 선택 후보 18/20 일치, 가중 L2 평균 1.4 mm |

선택 후보가 달라진 2개 clip의 가중 차이는 0.3 mm와 14.7 mm입니다. 5초 끝점과 목표점의 거리가 거의 같은 후보가 2개 있을 때, GPU 종류별 BF16 연산 차이로 선택이 바뀌는 경우입니다.

## 2. 학습 재현 (학습 서버 B200, 같은 코드와 seed)

| 재현 항목                                   | 원래                  | 재현                  |
|-----------------------------------------|---------------------|---------------------|
| 3단계만 재학습, held-out 모델 (검증 scenario 점수)  | 0.130237            | 0.130324            |
| 3단계만 재학습, 전체 데이터 모델 (학습 데이터 점수)         | 0.087320            | 0.087342            |
| 2단계 + 3단계 연쇄 재학습 (학습 데이터 점수, 2단계 / 3단계) | 0.091885 / 0.087320 | 0.091843 / 0.087321 |
| 연쇄 재학습 모델의 테스트 예측, 제출본과 비교              | —                   | 평균 2.3 cm           |

- 학습 시작 시점의 값은 비트 단위로 일치합니다.
- 학습 중간에는 곡선이 벌어졌다가 종료 시점에 수렴합니다. 원인은 BF16과 비결정적 CUDA 누적 연산입니다.
- 2단계 사전 점검(smoke) 결과는 다음과 같습니다.
  - 새 프로세스에서 다시 로드한 예측 차이 0.0
  - BN 통계 불변
  - ego 상태를 바꿔도 motion·상태 예측 변화 0.0

## 3. 제출물 구조 그대로 실행 (학습 영상 준비, 학습 forward/backward, 전체 추론)

제출물의 `tools/assemble.py`로 구성된 경로에서 실행한 결과입니다. 학습 서버(B200)에는 Docker가 없습니다. 그래서 B200에서는 사용자 권한 격리(proot)로 컨테이너와 같은 경로를 구성했고, B200의 PyTorch 2.10 환경을 사용했습니다.

4090에서는 제출 Docker 이미지를 사용했습니다.

| 항목                                                                                       | 환경                            | 결과                                                                                                                                                                                                   |
|------------------------------------------------------------------------------------------|-------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 학습 영상 준비<br>( <code>prepare_train.sh</code> ,<br>원본 tar 2개)                              | 4090,<br>Docker               | 영상 3,600장과 parquet 16개가 학습에 사용한 캐시와 바이트 단위로 모두 일치합니다                                                                                                                                                 |
| 학습 영상 준비, 원본 tar<br>376개 전체<br>( <code>tools/build_train_cache.py</code> )               | B200                          | 영상 676,800장과 parquet 3,008개가 학습에 사용한 캐시와 바이트 단위로 모두 일치합니다. crop과 카메라 행렬( <code>cache_meta.json</code> )도 같습니다                                                                                        |
| 1단계 smoke (2 update +<br>tune 1,998 평가)                                                  | B200                          | step 1 grad norm 8.681422 (원 기록 8.681418), 평가 d3 12.818012 (원 기록 12.818013)                                                                                                                          |
| 1단계 smoke,<br>microbatch 2                                                               | 4090<br>Docker                | 학습 샘플 순서 해시가 원 기록과 같습니다. loss 항목은 소수 넷째 자리까지 같고, grad norm은 8.681856(원 8.681418), 평가 d3는 12.818023(원 12.818013)입니다                                                                                   |
| 2단계 smoke (5 update +<br>평가·검증 probe)                                                    | B200                          | 평가 d3 0.106446 (원 기록 0.106435), 종료 코드 0                                                                                                                                                              |
| 2단계 smoke + verify,<br>microbatch 2                                                      | 4090<br>Docker                | 5 update의 샘플 순서 해시가 같고, 평가 d3는 0.106446(원 0.106435)입니다. verify에서 strict 재로드 후 예측 차이는 0.0입니다                                                                                                          |
| 3단계 smoke (20 update)                                                                    | B200 /<br>4090<br>Docker      | 두 환경 모두 정상 종료 (64 샘플 평가 0.1633 / 0.1647)                                                                                                                                                             |
| 1단계 전체 학습 (24,931<br>update, 공개 초기값에서<br>시작)                                             | B200                          | tune 1,998 평가 0.106857 (원 학습 0.106606, +0.24%). 중간 평가는 벌어졌다가(step 6,345: 0.276 / 0.230) 끝에서 수렴합니다. occupancy IoU 0.3974 (원 0.3980), lane IoU 0.3638 (원 0.3644)입니다. 학습 시간은 3.7시간입니다                   |
| 3단계 전체 학습 (6,344<br>update)                                                              | B200                          | tune 1,998 평가 0.087666 (원 학습 0.087320, +0.4%). 동결 몸통 파라미터 427개는 제출 checkpoint와 비트 단위로 같습니다. 학습 대상 planner의 상태 차이는 1.2%입니다. 같은 GPU에서 전체 추론을 동시에 실행했습니다                                                |
| 테스트 1,125 clip 전체 추<br>론<br>( <code>scripts/infer.sh</code> )                            | 4090,<br>Docker               | 약 7분이 걸립니다. 선택 후보는 1,118/1,125(99.4%)가 제출본과 같습니다. 같은 후보를 고른 clip의 좌표 최대 차이는 중앙값 1.5 mm, 최대 1.3 cm이고, 전체 가중 차이 평균은 0.9 mm입니다. FLOPs도 같습니다                                                             |
| 테스트 1,125 clip 전체 추<br>론 ( <code>infer.sh</code> 와 같은 명<br>령)                            | B200                          | 1,125 clip 모두 실제 제출 좌표와 완전히 일치합니다(최대 차이 0). <code>__flops__</code> 743,777,233,600으로 같습니다                                                                                                            |
| 저장한 이미지 파일<br>( <code>docker save</code> → 기존<br>이미지 삭제 → <code>docker<br/>load</code> ) | 4090                          | 같은 이미지 ID로 복원됩니다. <code>validate.sh</code> 결과도 같습니다(8/8, 18/20, 31.2 ms)                                                                                                                             |
| 용량을 줄인 제출 이미지<br>( <code>docker/Dockerfile.<br/>slim</code> ) vs 원래 이미지                  | RTX 4060<br>Laptop,<br>Docker | <code>validate.sh</code> 의 clip별 좌표 차이, 선택 후보, FLOPs가 두 이미지에서 완전히 같습니다. 실제 모델 forward·backward의 loss(0.007673), 기울기가 생긴 파라미터 수(305), 기울기 크기(0.181175)도 같습니다. 1·2·3단계 학습 모듈 import와 AdamW step도 정상입니다 |

- 1·2단계 코드는 시작할 때 GPU 여유 메모리가 약 174 GiB인지 검사합니다. B200 1단계 smoke는 다른 작업이 28 GB를 쓰는 GPU에서 실행했으므로, 이 사전 검사에 보고되는 여유 메모리만 늘렸습니다. 1단계 전체 학습은 빈 GPU에서 실행해 사전 검사를 그대로 통과했습니다. 1단계 코드는 `--gpu 0~3만` 받으므로, 이 실행은 CUDA를 해당 GPU에 먼저 연결한 뒤 장치 0으로 보이게 했습니다(Docker의 `--gpus`와 같은 효과). 두 경우 모두 소스 코드는 수정하지 않았습니다.

- 4090(24 GB)에서 1·2단계를 확인할 때는 `tools/small_gpu/sitecustomize.py`를 사용했습니다(`-e RELCHECK_MICROBATCH=2 -e PYTHONPATH=/shim`). `microbatch`는 8에서 2로 줄이고, 약 174 GiB 여유 메모리 사전 검사는 끝니다. 학습기는 전체 `batch(16)` 기준 `loss normalizer`로 `microbatch` 기울기를 누적하므로, 논리 `batch`와 계산식은 바뀌지 않습니다. `train.sh`는 이 도구를 사용하지 않습니다.
- 테스트 전체 추론을 하다가 `scripts/infer.sh`의 버그를 찾아 고쳤습니다. `clip`이 많으면 첫 `clip`을 고르는 `ls | head`가 `pipefail`에 걸려 스크립트가 바로 종료됐습니다. 20 `clip` 검증에서는 드러나지 않았습니다.